

[꼭지제목]북미에서는 wii, 일본에서는 GB가 왜 인기일까?


[중제목]0. 준비하기

물리팝은 게임 동아리의 핵심이다! 매달 새로운 게임을 추천하여 모두를 놀라게 한다. 최근에는 <Wii Sports>, <Pokemon>을 둘러싼 Wii와 GB의 인기에 흥미를 느꼈다. 'Wii는 북미에서, GB는 일본에서 인기가 많다'는 가설을 증명하기 위해 캐글 데이터 분석에 도전했다. 이번 분석이 동아리원들이 좋아할 게임을 발견하는 데 큰 도움이 될 것이다. 게임의 세계로 함께 떠날 준비가 되었는가?

캐글(Kaggle) 사이트에서 'Global Video Game Sales'라는 흥미로운 데이터셋을 다운로드해보자. 이 데이터셋은 vgchartz.com에서 제공한 것으로 전 세계 1만 6,598개 비디오게임의 판매량을 모아놓은 자료이다. 우리는 이 데이터를 통해 어떤 게임 플랫폼이 세계시장을 이끌고 있는지, 또한 각 지역에서 어떤 게임 장르가 가장 선호되는지 알아볼 수 있다. 더불어 시간이 흐르면서 게임의 인기 트렌드가 어떻게 변화하고 있는지도 살펴볼 수 있다.

이 데이터셋에는 게임의 이름, 플랫폼, 출시 연도, 출판사, 북미·유럽·일본과 기타 지역에서의 판매량과 세계 총판매량 등의 정보가 포함되어 있다. 이 정보를 바탕으로 세계에서 어떤 게임 플랫폼과 장르가 인기를 끌고 있는지 살펴보고, 특히 북미와 일본에서 가장 인기 있는 게임 플랫폼을 함께 분석해보자.

1



▶ 캐글 사이트의 'Global Video Game Sales'

[중제목]1. 알고 가기

데이터 시각화는 복잡한 정보를 쉽고 빠르게 이해할 수 있도록 돕는 매우 중요한

방법이다. 다양한 그래프, 차트, 지도와 같은 시각적 수단을 활용함으로써 데이터 속 숨겨진 패턴과 추세, 그리고 예외적인 사항들을 식별할 수 있게 해준다. 게임 데이터를 시각화하기 전에 시각화를 통한 데이터 분석의 기본 원리와 방법을 먼저 살펴보자.


데이터를 분석할 때 첫 번째로 해야 할 일은 우리가 다룰 데이터가 어떤 유형인지 알아보는 것이다. 데이터에는 수치형 데이터, 범주형 데이터가 있다. 예를 들어 게임 데이터셋을 살펴보면, 게임 판매량처럼 구체적인 숫자로 표현되는 것을 수치형 데이터라고 하고, 게임이 어느 플랫폼에서 나왔는지, 어떤 장르에 속하는지와 같이 여러 범주 중 하나로 분류할 수 있는 것을 범주형 데이터라고 부른다.

2

	A	B	C	D	E	F	G	H	I	J	K
1	Rank	Name	Platform	Year	Genre	Publisher	NA Sales	EU Sales	JP Sales	Other Sales	Global Sales
2	1	Wii Sports	Wii	2006	Sports	Nintendo	41.49	29.02	3.77	8.46	82.74
3	2	Super Mario Bros.	NES	1985	Platform	Nintendo	29.08	3.58	6.81	0.77	40.24
4	3	Mario Kart	Wii	2008	Racing	Nintendo	15.85	12.88	3.79	3.31	35.82
5	4	Wii Sports	Wii	2009	Sports	Nintendo	15.75	11.01	3.28	2.96	33
6	5	Pokemon	GB	1996	Role-Playing	Nintendo	11.27	8.89	10.22	1	31.37
7	6	Tetris	GB	1989	Puzzle	Nintendo	23.2	2.26	4.22	0.58	30.26
8	7	New Super Mario Bros.	DS	2006	Platform	Nintendo	11.38	9.23	6.5	2.9	30.01
9	8	Wii Play	Wii	2006	Misc	Nintendo	14.03	9.2	2.93	2.85	29.02
10	9	New Super Mario Bros.	Wii	2009	Platform	Nintendo	14.59	7.06	4.7	2.26	28.62
11	10	Duck Hunt	NES	1984	Shooter	Nintendo	26.93	0.63	0.28	0.47	28.31

▶ 다운받은 vgsales.csv 파일의 일부

3



▶ 데이터 유형의 분류도

데이터 분석의 핵심 단계 중 하나는 데이터를 시각적으로 표현하여 그 안의 정보를 더 잘 이해하는 것이다. 이 과정에서 우리는 데이터의 형태와 데이터 포인트 사이의 관계를 그림으로 나타내는 데 집중할 수 있다. 예를 들어, 산점도는 두 변수 사이의 관계를 보여주는 데 유용하며, 히스토그램은 데이터의 분포를 직관적으로 파악할 수 있게 해준다. 또한 분석하고자 하는 특정 목적에 부합하는 시각화 도구를

선택하는 것도 매우 중요하다. 시간에 따른 데이터의 변화를 추적하고 싶다면 선 그래프를 활용하고, 서로 다른 범주를 비교하고자 한다면 막대그래프를 사용하는 것이 좋다. 이처럼 분석 목적에 적합한 시각화 방법을 선택함으로써 데이터의 중요한 특징을 더 명확하게 드러내고, 이해하기 쉬운 형태로 정보를 표현할 수 있다.

데이터 분석의 마무리 단계에서는 시각화를 통해 표현된 데이터를 분석하여 그 의미를 해석하는 과정이 포함된다. 예를 들어, 특정 플랫폼에서 게임 판매량이 눈에 띄게 높다면 이는 해당 플랫폼에서의 게임 인기를 반영하는 것일 수 있다. 이 과정은 데이터에서 숨겨진 의미를 발견하고 그 결과를 바탕으로 우리가 정보에 기반한 결정을 내릴 수 있게 도와준다.


[중제목]2. 전처리하기

오렌지3를 사용해서 ‘Global Game Sales’ 데이터를 살펴보고 준비하는 과정은 정말 쉽다. 우리가 해야 할 첫 걸음은 [File] 위젯을 열어 CSV 파일 형식의 데이터를 불러오는 것이다.

이 데이터를 열어보면 Info 부분에서 비디오게임 1만 6,598개에 대한 정보가 담겨 있는 것을 확인할 수 있다. 이 정보에는 게임의 이름, 출시 연도, 출판사와 같은 중요한 메타데이터가 포함되어 있고, 더 나아가 데이터 분석을 위해 준비된 8개의 다른 속성들이 있다. Columns 부분을 조사해보면 대부분의 속성이 판매량을 나타내는 NA_Sales, EU_Sales, JP_Sales 같은 수치형 데이터로 구성되어 있음을 알 수 있다. 또한 게임의 플랫폼과 장르 같은 카테고리형 데이터도 포함되어 있어 우리에게 분석의 다양한 가능성을 열어준다. 또한, 우리가 사용할 게임 데이터셋에는 결측치가 없어서 데이터를 분석하기 위한 준비 과정에서 결측치를 다루는 단계를 생략할 수 있다.

이번엔 데이터 파일 창에서 Columns 부분을 통해 각 데이터 속성의 역할을 확인할 수 있는데, 이번 분석에서는 시각화를 중심으로 할 것이기 때문에 속성 중 특정 속성을 ‘target’으로 변경하지 않고 기본 설정된 ‘feature’ 역할로 그대로 두기로 한다.

4



▶ CSV 파일 불러오기

데이터 준비를 마치고 나면 시각화를 이용해 데이터 속 숨겨진 패턴과 추세를 찾아 보는 단계로 넘어갈 수 있다. [Data Table] 위젯을 연결하여 우리가 가진 데이터셋을 자세히 들여다보면 게임의 이름, 출판사, 순위, 플랫폼, 장르, 그리고 북미·유럽·일본과 그 외 지역의 판매량과 세계 판매량이 모두 포함되어 있음을 확인할 수 있다. 데이터셋에는 다양한 플랫폼에서 즐길 수 있는 게임들과 스포츠, 액션, 플랫폼, 레이싱, 어드벤처와 같은 여러 장르의 게임들이 포함되어 있어, 이러한 정보를 시각화하여 볼 수 있다.

5

Rank	Name	Year	Publisher	Rank	Platform	Genre	NA_Sales	EU_Sales	JP_Sales	Other_Sales	Global_Sales
180	Mad Max 2	N/A	Electronic Arts	180	PS2	Sports	4.26	0.26	0.01	0.71	5.24
179	PGA Tour 2K	N/A	Electronic Arts	179	PS2	Sports	0.08	2.16	0.04	0.01	2.29
178	UFC 2006	N/A	Warner Bros. L.	178	Wii	Action	1.86	0.02	0.00	0.00	1.88
177	UFC 2006	N/A	N/A	177	PS2	Fighting	1.57	1.02	0.00	0.01	2.60
176	UFC 2006	N/A	N/A	176	Wii	Shooter	2.48	0.04	0.00	0.00	2.52
175	Rock Band	N/A	Electronic Arts	175	PS2	Music	1.81	0.14	0.00	0.21	2.16
174	Rock Band	N/A	Electronic Arts	174	Wii	Music	2.71	0.16	0.00	0.02	2.89
173	Call of Duty 3	N/A	Activision	173	Wii	Shooter	1.19	0.04	0.00	0.21	1.44
172	Call of Duty 3	N/A	Activision	172	PS2	Shooter	1.19	0.04	0.00	0.21	1.44
171	Call of Duty 3	N/A	Activision	171	Wii	Shooter	0.08	0.01	0.00	0.24	0.33
170	Call of Duty 3	N/A	Activision	170	PS2	Shooter	0.08	0.01	0.00	0.24	0.33
169	Call of Duty 3	N/A	Activision	169	Wii	Shooter	0.08	0.01	0.00	0.24	0.33
168	Call of Duty 3	N/A	Activision	168	PS2	Shooter	0.08	0.01	0.00	0.24	0.33
167	Call of Duty 3	N/A	Activision	167	Wii	Shooter	0.08	0.01	0.00	0.24	0.33
166	Call of Duty 3	N/A	Activision	166	PS2	Shooter	0.08	0.01	0.00	0.24	0.33
165	Call of Duty 3	N/A	Activision	165	Wii	Shooter	0.08	0.01	0.00	0.24	0.33
164	Call of Duty 3	N/A	Activision	164	PS2	Shooter	0.08	0.01	0.00	0.24	0.33
163	Call of Duty 3	N/A	Activision	163	Wii	Shooter	0.08	0.01	0.00	0.24	0.33
162	Call of Duty 3	N/A	Activision	162	PS2	Shooter	0.08	0.01	0.00	0.24	0.33
161	Call of Duty 3	N/A	Activision	161	Wii	Shooter	0.08	0.01	0.00	0.24	0.33
160	Call of Duty 3	N/A	Activision	160	PS2	Shooter	0.08	0.01	0.00	0.24	0.33
159	Call of Duty 3	N/A	Activision	159	Wii	Shooter	0.08	0.01	0.00	0.24	0.33
158	Call of Duty 3	N/A	Activision	158	PS2	Shooter	0.08	0.01	0.00	0.24	0.33
157	Call of Duty 3	N/A	Activision	157	Wii	Shooter	0.08	0.01	0.00	0.24	0.33
156	Call of Duty 3	N/A	Activision	156	PS2	Shooter	0.08	0.01	0.00	0.24	0.33
155	Call of Duty 3	N/A	Activision	155	Wii	Shooter	0.08	0.01	0.00	0.24	0.33
154	Call of Duty 3	N/A	Activision	154	PS2	Shooter	0.08	0.01	0.00	0.24	0.33
153	Call of Duty 3	N/A	Activision	153	Wii	Shooter	0.08	0.01	0.00	0.24	0.33
152	Call of Duty 3	N/A	Activision	152	PS2	Shooter	0.08	0.01	0.00	0.24	0.33
151	Call of Duty 3	N/A	Activision	151	Wii	Shooter	0.08	0.01	0.00	0.24	0.33
150	Call of Duty 3	N/A	Activision	150	PS2	Shooter	0.08	0.01	0.00	0.24	0.33


▶ 데이터셋 확인하기

우리가 탐구할 데이터셋에는 수많은 게임 정보가 담겨 있어서, 이 모든 것을 한꺼번에 파악하려면 어려움을 느낄 수 있다. 이러한 상황에서 효율적으로 데이터를 분석하고 이해하기 위해 Rank란에 기록된 상위 50개 게임에 집중하기로 한다. 더불어 데이터 테이블을 꼼꼼히 조사해보면, Year란에 'N/A'라고 적힌 정보, 즉 출시 연도가 기록되지 않은 게임들이 있다는 걸 발견할 수 있다. 이것은 몇몇 게임의 출시 연도가 빠져 있다는 뜻이다. 하지만 운이 좋게도 우리가 주목하려는 상위 50위에 랭크된 게임 중에서는 출시 연도 정보가 빠진 게임이 없어, 별다른 데이터 정리 작

업 없이도 분석을 시작할 수 있다.

이 과정을 위해 [Select Rows] 위젯을 활용한다. 우선, [Select Rows] 위젯을 [Data Table] 위젯에 연결한 후 Rank 항목이 '51 미만'인 데이터만을 선별하는 작업을 진행한다. '51 미만'이라는 조건을 사용하면, 'is below' 조건에 의해 50위까지의 게임 정보만을 정확히 추려낼 수 있다. 이 'is below' 조건은 설정한 값보다 낮은 데이터만을 선택해줌으로써, 분석해야 할 주요 게임들만을 효율적으로 골라낼 수 있게 해준다.

6



▶ 데이터 필터링

7




▶ 데이터 처리 흐름도

[중제목]3. 시각화하기

[소제목] 막대그래프 사용하기

우리의 분석 목표는 세계에서 어떤 게임 플랫폼과 장르가 가장 인기 있는지, 특히 북미와 일본에서 선호되는 게임 플랫폼을 시각화를 통해 분석해보는 것이다. [Select Rows] 위젯에 [Data Table] 위젯을 하나 더 연결하여 상위 50위 게임들만 모아졌는지 확인해보자. 이제 [Bar Plot] 위젯을 사용하여 글로벌 판매량에서 상위 50위 안에 드는 게임들을 막대그래프로 표현해볼 것이다. 이 플롯을 통해 각 게임의 세계적인 판매 성공 순위를 쉽게 비교해볼 수 있다. 막대의 높이가 게임의 세계 판매량을 나타내므로 이를 통해 성공적인 게임들의 공통된 특징을 파악할 수 있고, 어떤 플랫폼이나 장르가 사람들에게 인기가 있는지 분석하는 우리의 목표에 점점 더 가까워지게 된다.

8



▶ 플랫폼과 장르별 글로벌 게임 판매 동향

이 플롯은 막대그래프를 통해 비디오게임 판매 데이터의 장르별 및 플랫폼별 글로벌 판매량을 시각화한 것이다. 그래프에서 x축은 게임 플랫폼을 나타내고, y축은 해당 플랫폼에서 판매된 게임의 세계 판매량을 나타낸다. 다양한 색상의 막대는 각기 다른 게임 장르의 판매량을 나타낸다.

눈에 띄는 것은 Wii, NES 그리고 DS 플랫폼에서의 높은 판매량이며, Wii는 특히 스포츠 장르에서 두드러진 판매량을 보이고 있다. 이 플롯으로 시장에서의 플랫폼과 장르의 인기를 비교해볼 수 있다.

9



▶ 데이터 처리 흐름도


[소제목] 산점도 사용하기

산점도 시각화를 위해 [Scatter Plot] 위젯을 활용하기 전에 또 다른 중요한 단계가 있다. 그것은 바로 [Preprocess] 위젯을 통해 데이터를 정리하는 과정이다. [Preprocess] 위젯을 이용하면 수치 데이터를 0과 1 사이의 값으로 변환할 수 있는데, 이 과정을 ‘정규화’라고 부른다. 정규화는 다양한 크기의 데이터를 비슷한 범위 안으로 조정하여 데이터 간의 비교를 더욱 쉽게 해준다.

[Preprocess] 위젯의 Preprocessors에서 ‘Normalize Features’ 옵션을 선택하고, ‘Normalize to interval [0,1]’ 옵션을 고른다. 데이터를 이렇게 정규화한 뒤에는 [Preprocess] 위젯에 [Scatter Plot] 위젯을 연결하고 시각화를 계속한다. 이런 단계를 거치면 데이터 분석이 훨씬 더 명확하고 효율적으로 이루어진다.

데이터를 정규화하는 것은 복잡해 보일 수도 있지만 사실 데이터 분석에서 매우 중요한 과정 중 하나로, 우리가 데이터를 더 잘 이해하고 올바른 결론을 도출하는 데 도움을 준다.

10



▶ 특성 정규화하기


Tip> Normalize Features

비디오게임 판매량 데이터를 정리할 때는 여러 가지 방법을 사용할 수 있는데, 분석의 목적이나 데이터의 특징을 잘 고려해서 결정해야 한다.

- **Standardize to $\mu=0$, $\sigma=1$ (표준화, 평균=0, 표준편차=1):** 데이터가 평균을 중심으로 어떻게 퍼져 있는지 보여준다. 데이터가 벨 모양의 정규분포를 따른다면 이 방법이 좋으며, 기계학습 같은 복잡한 계산을 할 때 유용하게 쓰인다.
- **Center to $\mu=0$ (중앙집중화, 평균=0):** 모든 데이터를 평균값을 기준으로 분석하고 싶을 때 적합하다. 예를 들어 게임들이 전체 판매량의 평균에서 얼마나 차이가 나는지 알고 싶을 때 사용된다.
- **Scale to $\sigma=1$ (척도 조정, 표준편차=1):** 이 방법은 변동성, 즉 데이터가 얼마나 많이 변하는지가 중요할 때 사용할 수 있다. 게임 판매량의 변동 폭을 같게 만들고 싶을 때 좋다.
- **Normalize to interval $[-1, 1]$ (구간 정규화 -1에서 1):** 최솟값과 최댓값을 기준으로 모든 값을 -1과 1 사이로 조정하는 방법이다. 판매량의 상대적 크기를 비교하고 싶을 때 효과적이다.
- **Normalize to interval $[0, 1]$ (구간 정규화 0에서 1):** 모든 값을 0과 1 사이로 맞춘다. 특히 모든 값이 양수일 때, 그리고 데이터를 비율이나 확률로 해석하고 싶을 때 유용하다.

보통은 비디오게임 판매량 같은 데이터를 0과 1 사이로 맞추는 구간 정규화 방법이 많이 사용되는데, 이렇게 하면 데이터 포인트들을 직관적으로 쉽게 비교할 수 있다. 하지만 어떤 정규화 방법을 사용할지는 하고 싶은 분석 종류나 사용하고자 하는 분석 도구에 따라 달라질 수 있다.

11



▶ 유럽과 북미 게임 판매량 비교

이 플롯은 [Scatter Plot] 위젯을 이용한 산점도로, 두 변수 간의 관계를 시각적으로 표현한 그래프이다. 이 그래프에서 x축은 유럽 판매량을, y축은 북미 판매량을


나타낸다. 각 점은 하나의 게임을 나타내며, 점의 위치는 그 게임의 유럽과 북미 지역에서의 판매량에 대응한다.

이 플롯에서 대부분의 데이터 포인트(게임)는 낮은 판매량 범위에 몰려 있으며, 이는 게임 대부분이 중간 이하의 판매량을 기록한다는 것을 의미한다.

북미와 유럽 판매량 사이에 일정 수준의 양의 상관관계가 있어 보이는데, 이는 한 지역에서 판매량이 높은 게임은 다른 지역에서도 비교적 높은 판매량을 보일 가능성이 있다는 것을 나타낸다. 몇몇 점들은 y축이나 x축 근처에 위치하고 있어 한 지역에서는 높은 판매량을 보이지만 다른 지역에서는 그렇지 않은 게임들도 존재함을 보여준다.

우측 상단에는 'Wii Sports'라는 라벨이 보이는데, 이는 그 게임이 북미와 유럽에서 매우 높은 판매량을 기록했음을 나타낸다.

12



▶ 일본과 북미 게임 판매량 비교

이 플롯은 다양한 게임 플랫폼에서의 일본과 북미 지역의 게임 판매량을 비교한 것으로 x축은 일본 판매량을, y축은 북미 판매량을 나타낸다. 점의 모양은 플랫폼을 구분하며, DS는 원 모양, GB는 X 모양, PS2는 삼각형, Wii는 플러스 기호, X360은 마름모, Other은 별 모양으로 표현되고 있다.

대부분 게임은 낮은 판매량 범위에 집중되어 있으며, 일본 판매량이 낮은 게임은 북미에서도 비슷하게 낮은 경향을 보인다. 하지만 특정 게임의 판매량은 지역에 따라 크게 달라질 수 있는데, 일본에서는 낮은 판매량을 보이지만 북미에서는 높은 판매량을 기록하는 경우가 있고, 반대로 북미에서는 상대적으로 낮은 판매량을 보이지만 일본에서는 높은 판매량을 달성하는 예도 보인다. 북미에서 높은 판매량을 보이는 것은 Wii 플랫폼의 <Wii Sports>이고, 일본에서 높은 판매량을 보이는 것은 GB플랫폼의 <Pokemon>으로, 이는 지역별 시장 선호도의 차이를 반영한다.


Tip> Jittering

Jittering은 데이터 시각화에서 아주 유용한 기술로, 우리가 데이터 포인트들을 더 잘 볼 수 있게 도와준다.

가끔 데이터를 점으로 표현할 때, 많은 점이 한 곳에 몰려 있거나 서로 너무 가까이 있어서 구분하기 어려울 때가 있다. 이럴 때 Jittering 기술을 사용하면 점들을 약간씩 옮겨서 서로 겹치지 않고 각각의 데이터 포인트를 더욱 분명하게 볼 수 있게 해주며, 데이터가 어떻게 분포되어 있는지 파악하기 쉽게 도와준다.

하지만 Jittering 을 너무 많이 사용하면 데이터 포인트들이 원래 있던 자리에서 너무 멀어져서 실제 데이터의 모습과 다르게 보일 수 있다. 그래서 이 기술은 적절히 사용하는 것이 중요하다.


13



▶ 데이터 처리 흐름도

[소제목] 모자이크 그래프 사용하기

[Mosaic Display] 위젯은 비디오게임 판매 데이터 같은 복잡한 정보를 이해하는데 아주 효과적인 방법이며, 특히 범주형 데이터에서 두 변수 간의 관계를 시각화하는 데 유용한 도구이다. 우리는 지역별 판매량, 장르, 플랫폼 등 다양한 변수 간의 관계와 패턴을 타일 형태의 그래프로 시각화할 수 있다.



▶ 북미 게임 시장의 플랫폼별 판매량 분포

이 모자이크 플롯은 북미 지역의 판매량과 다양한 게임 플랫폼 간의 관계를 나타내고 있다. 세로축은 게임 플랫폼을 나타내며, 여기에는 SNES, PS4, PS3, PS2, NES, DS, 3DS 등 다양한 플랫폼이 표시되어 있다. 가로축은 북미 판매량을 범위에 따라 나누어 표시한다. 여기에는 판매량의 수치 범위가 주어져 있으며, 예를 들어 ‘ < 5.67 ’, ‘ 5.67-8.33 ’ 와 같이 구분된다. 각 플랫폼과 판매량 범위의 결합은 블록의 상대적인 크기로 표현되며, 내부 색상은 피어슨 잔차(Pearson residuals)로 결정된다. 피어슨 잔차는 기댓값과 관찰 값의 차이를 표준화하여 보여주는데, 색상의 강도는 잔차의 크기를 나타내며, 빨간색은 음의 잔차, 파란색은 양의 잔차를 의미한다.

이 플롯에서 피어슨 잔차는 일부 플랫폼이 특정 판매량 범위에서 기대치를 초과하거나 미달하는 것을 나타내며, 3DS 플랫폼은 ‘ < 5.67 ’ 범위에서 큰 파란색 블록을 가지고 있어 이 범위에서 예상보다 더 많은 판매가 있었음을 보여준다.

Tip> 피어슨 잔차


피어슨 잔차는 관측된 빈도(O)와 기대되는 빈도(E) 사이의 차이를 기대되는 빈도의 제곱근으로 나눈 값으로 계산된다. 공식은 다음과 같다.

$$r = \frac{O - E}{\sqrt{E}}$$

(O: 관측된 빈도, E: 기대되는 빈도, r: 피어슨 잔차)

피어슨 잔차의 절댓값이 클수록, 관측된 값과 기대되는 값 사이에 더 큰 차이가 있음을 의미한다. 일반적으로 절댓값이 2 이상이면 통계적으로 유의미한 차이가 있다고 간주할 수 있다. 모자이크 플롯에서 피어슨 잔차를 사용하여 색상을 지정하면, 기대치와 가장 크게 벗어난 범주를 시각적으로 쉽게 파악할 수 있다.


15



▶ 일본 게임 시장의 플랫폼별 판매량 분포

이 모자이크 플롯은 일본의 게임 판매량과 다양한 게임 플랫폼 간의 관계를 나타낸다. 세로축은 게임 플랫폼을 나타내며, 가로축은 일본 판매량의 범위를 표시한다. 이 경우 판매량의 범위는 ‘ < 0.44 ’, ‘ $0.44-2.8$ ’, ‘ $2.8-4.17$ ’, ‘ ≥ 4.17 ’로 나누어져 있다. X360 플랫폼은 ‘ < 0.44 ’ 판매량 범위에서 큰 파란색 블록이 있다. 이는 이 범위에서 예상보다 많은 판매가 있었다는 것을 나타낸다. DS, GB 플랫폼들은 ‘ $2.8-4.17$ ’ 및 ‘ ≥ 4.17 ’ 범위에서 더 큰 블록을 가지고 있는데, 이는 이들 플랫폼의 게임들이 이 판매 범위에서 높은 판매를 보였음을 의미한다.

16




▶ 북미 대 일본 게임 플랫폼별 판매량 비교

이 플롯은 두 가지 수치형 변수인 북미 판매량과 일본 판매량을 범주형으로 나누어 비교하고, 내부 색상은 다양한 게임 플랫폼을 나타내도록 표현하였다. 판매량이 높은 범위(가로축 오른쪽과 세로축 상단)에 해당하는 블록이 크다는 것은 해당 판매량 범위에서 상대적으로 많은 게임이 팔렸음을 나타낸다. 예를 들어, 가장 오른쪽 상단의 큰 연은 분홍색 블록은 GB 플랫폼이 북미와 일본 모두에서 높은 판매량을 기록했다는 것을 의미한다. 반대로 왼쪽 하단의 작은 블록들은 낮은 판매량

을 가진 플랫폼들을 나타낸다.

17




▶ 다차원 모자이크 그래프

[Mosaic Display] 위젯을 사용하면, 데이터를 쉽게 다루고 자세히 볼 수 있지만, 'Find Informative Mosaics' 같은 특별한 기능을 사용하면 우리가 직접 찾지 않아도 컴퓨터가 알아서 중요한 정보의 변수들을 조합해준다.

하지만 [Mosaic Display]는 변수의 값이 다양한 데이터셋에 대해서는 복잡하고 해석하기 어려운 그래프를 만들 수 있다는 점을 기억해야 한다. 위의 그래프는 매우 많은 데이터 포인트를 포함하고 있으며, 이로 인해 각 타일이 매우 세밀하게 나뉘어 있는 것을 볼 수 있다. 이 경우 데이터를 더 명확하게 분석하고 해석하기 위해서는 추가적인 데이터 처리 또는 다른 시각화 방법을 고려해야 한다.

18



▶ 데이터 처리 흐름도

[중제목]4. 정리하기

게임 데이터셋을 활용해 여러 시각화 기법으로 세계적으로 인기 있는 게임 플랫폼

과 장르를 시각화해보았다. 특히 북미와 일본 시장에서 인기 있는 플랫폼을 집중적으로 살펴보면, 롤리팝이 가졌던 ‘Wii는 북미에서, GB는 일본에서 인기가 많다’는 가설을 증명하기 위한 정보들을 살펴보았다.

막대그래프를 이용한 분석에서는 세계시장에서 Wii가 큰 성공을 거둔 것을 알 수 있었고, 산점도로는 북미와 일본의 판매량 사이의 관계를 시각화하여 두 지역에서 인기 있는 플랫폼 간의 상관관계를 살펴볼 수 있었다. 이 플롯에서 지역별 시장 선호도의 차이도 볼 수 있었는데, 북미에서는 Wii가 일본에서는 GB가 가장 판매량이 높은 플랫폼임을 확인할 수 있었다.

모자이크 플롯을 통해서는 지역별 판매 데이터와 게임 플랫폼 간의 관계를 더욱 복잡한 다중 레벨 분석으로 볼 수 있었는데 일본에서는 GB의 판매량이, 북미에서는 Wii의 판매량이 각각 눈에 띄게 가장 많은 비중을 차지하며 주목받았다.