

3-5

[꼭지제목]우리가 사는 지구의 환경은 시간이 지나면서 어떤 변화를 겪고 있을까?


(예측 분석, Time Series)

[중제목]0. 준비하기

롤리팝은 환경 수업에서 선생님의 강의를 들으며 지구 온난화와 생태계 변화에 관한 이야기에 귀를 기울였다. 선생님의 말씀에 흥미를 느낀 롤리팝은 환경 문제에 대해 더 깊이 생각해보게 되었다. 그때 선생님께서 중요한 말씀을 하셨다. "환경 데이터를 분석하는 일은 우리가 지금 당면한 문제들을 이해하고 해결책을 찾는 데 매우 중요해요." 선생님의 이 말씀에 영향을 받아 롤리팝은 실제 데이터를 분석하여 환경 문제에 대한 자신의 이해를 심화시키고자 결심했다.

캐글 사이트에서 'Climate Insights Dataset'이라는 데이터셋을 찾아 다운로드해 보자. 이 데이터셋은 우리 기후가 시간에 따라 어떻게 변화하는지 귀중한 정보를 제공한다. 기온, 이산화탄소 배출량, 해수면 상승 등의 자료가 포함되어 있어서 전 세계의 기후 변화 추세를 분석하는 데 매우 유용하다. 이 데이터를 활용하면 연구자, 과학자뿐만 아니라 기후 변화에 관심이 있는 모든 사람이 지구에 미치는 영향을 조사할 수 있다. 우리는 이 데이터셋을 오렌지3의 Time Series 탭을 사용하여 시간에 따라 분석하고 미래를 예측해 볼 것이다.

1



▶ 캐글 사이트의 'Climate Insights Dataset'

[중제목]1. 알고가기

예측적 데이터 분석은 기존 데이터를 활용하여 미래의 사건, 결과, 행동 등을 예측하는 과정이다. 이 방법은 과거의 데이터 패턴을 분석하여 미래의 불확실성을 줄이고, 좀 더 정보에 기반한 의사결정을 가능하게 한다.

상상해 보라. 당신이 음식점을 운영한다고 할 때, 다가오는 주말에 몇 명의 고객이 올지 예측할 수 있다면 얼마나 좋을까? 예측적 데이터 분석을 통해, 과거의 방문 데이터, 이벤트, 날씨 등 다양한 요인을 분석하여 주말의 고객 수를 예측할 수 있다. 이 정보를 바탕으로 필요한 재료를 미리 준비하거나, 직원 스케줄을 조정하여 서비스의 질을 높이고 낭비를 줄일 수 있다.

예측적 데이터 분석은 다양한 장점과 단점을 가지고 있다. 먼저 장점으로는 미래 예측을 통해 정보에 기반한 정확한 의사결정을 가능하게 하다. 이를 통해 가능한 미래 시나리오를 이해함으로써 발생 가능한 리스크를 미리 파악하고 대비할 수 있다. 또한, 자원 배분과 운영의 효율성을 최적화하며 경제적 비용을 절감하다.

반면, 단점으로는 분석의 정확도가 사용된 데이터의 품질과 양에 크게 의존하다는 점이다. 이에 따라 데이터가 부족하거나 품질이 낮은 경우 예측의 신뢰성이 떨어질 수 있다. 또한, 과적합 위험이 있는데, 이는 모델이 훈련 데이터에 지나치게 적합되어 실제 상황에서 새로운 데이터에 대한 예측이 부정확하다. 마지막으로, 경제, 사회, 기술의 급격한 변화는 모델의 예측력을 감소시킬 수 있는데, 이는 변화하는 환경에 모델이 유연하게 대응하지 못하기 때문이다.

예측적 데이터 분석의 일반적인 단계는 다음과 같다:

1단계 문제 정의: 문제를 정의 및 예측의 종류 결정

2단계 데이터 수집: 분석에 필요한 데이터를 수집

3단계 데이터 탐색: 수집된 데이터 탐색 및 분석

4단계 데이터 전처리: 결측치 처리, 데이터 정제 및 변환

5단계 모델 구축 및 훈련: 적합한 예측 모델 선택 및 훈련

6단계 모델 평가 및 선택: 모델의 성능 평가 및 최종 모델 선택

7단계 예측 수행 및 적용: 미래를 예측하고, 이 결과를 실제 의사결정 과정에 적용

시계열 분석은 예측적 데이터 분석의 핵심 요소로, 시간의 흐름에 따라 발생하는 데이터의 패턴과 관계를 세밀하게 분석하여 미래를 예측하며, 이러한 분석을 통해 얻은 통찰력은 효과적인 의사결정에 중요한 역할을 한다. 이에 우리는 오렌지3의 Time Series 탭에 있는 다양한 위젯을 활용하여 시계열 데이터셋에 예측적 데이터 분석의 단계를 적용해 볼 예정이다.

자, 이제 우리가 사는 지구의 환경의 변화를 이해하고 예측하기 위해 기후 데이터셋을 이용한 시계열 분석에 도전해 보자.


오렌지3에서 Time Series 탭을 사용하기 위해서는 'Options' 메뉴에서 'Add-ons'를 선택하여 'Timeseries'를 체크하고 설치하면 된다.

[중제목]2. 시계열 데이터 분석하기

[소제목]데이터 불러오기 및 전처리

먼저, 오렌지3의 [File] 위젯을 사용하여 'climate_change_data.csv' 파일을 불러온다. 이 위젯을 통해 데이터셋의 기본적인 정보를 확인할 수 있으며, 필요한 경우 변수의 타입(Type)을 조정할 수 있다.

2




▶ CSV 파일 불러오기

두 번째로 [File] 위젯에 [Preprocess] 위젯을 연결한다. [Preprocess] 위젯은 데이터의 전처리 과정에서는 결측치 처리, 변수 선택, 데이터 정규화 같은 작업을 수행한다:

- ① Select Relevant Features(변수 선택): 기후 데이터 분석에서는 분석 목적에 맞게 관련 있는 변수만을 선택해야 한다. 'Select Relevant Features'를 선택하면 자동으로 데이터에 대한 가장 유의미한 기능을 선택할 수 있다.
- ② Normalize Features(데이터 스케일링): 기후 데이터는 스케일링을 통해 모델의 성능을 향상시킬 수 있다. 'Scale to 0,1' 또는 'Standardize to $\mu=0$, $\sigma=1$ ' 중 하나를 선택하여 변수의 스케일을 조정할 수 있다. 'Standardize to $\mu=0$, $\sigma=1$ '는

데이터의 평균을 0, 표준편차를 1로 조정하여 모든 변수가 같은 스케일을 갖도록 한다. 시계열 데이터의 경우, 각 변수가 시간에 따라 어떻게 변하는지를 파악하는 것이 중요하므로 스케일링은 신중하게 결정해야 한다.


3



▶ 데이터 전처리

우리가 사용하는 데이터셋은 결측치가 없는 상태로, 이는 전처리 과정을 진행할 때 큰 이점이 된다. 따라서, 전처리 과정에서 변수 선택과 데이터 스케일링만 설정하기로 한다. 변수 선택에서 Proportion을 75%로 설정한다. 이는 알고리즘이 평가한 전체 특성 중 가장 높은 점수를 받은 상위 75%의 특성들만을 선택하겠다는 의미로, 이렇게 함으로써 데이터 내에서 가장 유용하다고 판단되는 특성들로 데이터 세트를 줄일 수 있다.

3-1




▶ 데이터셋 확인하기

[Preprocess] 위젯에 [Data Table] 위젯을 연결하면 Temperature, CO2 Emissions, Sea Level Rise, Precipitation 변수가 유용하여 선택된 것을 확인할 수 있다.

세 번째로 [Preprocess] 위젯에 [Edit Domain] 위젯을 연결한다.

4



▶ 변수 타입 변경하기

[File] 위젯에서 확인해보면 Date 변수가 텍스트 형식으로 되어 있어 메타데이터로 처리되게 되어 있는데, 이는 주로 분석 작업에서는 사용되지 않는 정보를 포함할 때 사용되는 방식이므로 Date 변수를 시간 변수로 재해석하는 작업이 필요하다. [Edit Domain]을 통해 Date 변수를 선택하고, 변수의 타입을 Time으로 변경한다.

마지막으로 Time Series 탭에서 [Form Timeseries] 위젯을 찾아 [Edit Domain] 위젯에 연결한다.

5




▶ 데이터 처리 흐름도

이미 [Edit Domain] 위젯을 통해 Time으로 설정된 변수가 있는 경우에도 [Form Timeseries] 위젯에서 해당 변수를 'Select the column with date' 옵션을 통해 날짜 열로 지정해주는 것이 좋다. 이렇게 하면 데이터가 시계열 데이터로 인식되어, 시계열 분석이나 다른 시계열 관련 작업을 수행할 때 정확한 처리가 가능하다.

[소제목]데이터 탐색 – 주기성 파악

시계열 데이터를 분석할 때는 데이터의 주기적 패턴과 계절성을 분석하기 전에 데이터를 전처리하는 것이 중요하다. 이는 데이터의 일관성과 정확성을 높이기 위해서이다. 이번 단계에서 데이터 탐색을 위해 사용할 위젯은 [Periodgram]이다. 이 위젯은 데이터 내에서 가장 강한 주기를 식별할 수 있고, 데이터의 계절적 변화나 주기성에 대한 통찰력을 얻을 수 있다. 예를 들어 한 지역에서 매년 여름이 되면 기온이 얼마나 올라가는지, 혹은 겨울철에는 어떤 변화가 있는지 같은 계절적인 변화를 찾는 것과 같다. 마치 날씨를 예측하는 일기예보처럼, 이 위젯은 한 해 동안의 기온 변화에서 가장 강한 변화의 패턴이나 주기를 찾아낸다. 이를 통해 봄이 시작될 때마다 꽃이 피는 것처럼, 데이터에서도 특정 시간이나 계절에 일어나는 중요한 변화를 식별할 수 있다. 이러한 정보는 미래의 기후 패턴을 예측하고 계절에 따른 변화를 이해하는 데 유용하게 쓰인다. [Periodgram] 위젯을 [Form Timeseries] 위젯에 연결한다.

8




▶ 기온 데이터에 대한 주기성 분석

이 플롯에서 관찰되는 주기성(Periodogram)은 x축은 'period(days)'로 각 주기를 나타내고, y축은 각 주기에 해당하는 파워 스펙트럼의 강도를 보여준다. 기온 데이

터의 주기적 변동성을 나타내며, 각 막대가 일정한 시간 간격(주기)을 나타내고, 그 주기의 길이가 '일'로 측정되고 있다. 예를 들어, 막대 하나가 60일 주기를 나타낸다면, 이는 어떤 반복되는 패턴이나 사건이 60일마다 한 번씩 발생한다는 것을 의미한다. [Periodogram] 위젯은 이러한 주기들을 분석하여, 시계열 데이터에서 어떤 주기들이 가장 중요하거나 뚜렷하게 나타나는지를 보여준다.


분석에서 75일 정도의 위치에 나타난 가장 높은 막대는 그 주기가 기온 데이터에서 두드러지게 나타나는 강력한 신호임을 보여준다. 이는 데이터가 특정한 주기성을 따라 변화하고 있음을 의미하며, 이 변화는 계절적 패턴이나 기후적 특성과 관련 있을 가능성이 있다.

9




▶ 이산화탄소(CO₂) 데이터에 대한 주기성 분석

이 플롯은 이산화탄소(CO₂) 배출 데이터에 대한 주기성 분석 결과이다. 20일 근처의 높은 봉우리는 CO₂ 배출량 데이터에서 20일 주기를 가진 주기적 변화가 상대적으로 높은 강도를 가지고 있음을 나타낸다. 또한, 20, 40, 60, 80, 100일 등 규칙적인 간격으로 높은 봉우리가 나타나는 것은 CO₂ 배출량 데이터에 명확한 주기적 패턴이 있다는 것을 나타낸다. 이러한 규칙적인 간격의 봉우리들은 제조 공정, 에너지 수요의 주기적 변화, 또는 농업 활동과 같은 경제적 사이클을 반영할 수 있다. 예를 들어, 농업 분야에서 비료를 뿌리거나 특정 작물을 수확하는 등의 활동이 정기적으로 이루어질 때, 해당 기간 농업 기계 사용이 증가하면서 CO₂ 배출량에 영향을 줄 수 있다. 이렇게 주기적으로 나타나는 봉우리들은 그러한 활동의 주기를 반영할 가능성이 있다.



▶ 해수면 상승 데이터에 대한 주기성 분석

이 플롯에 나타난 40일과 140일 근처의 높은 봉우리들은 해수면 상승 데이터에서 해당 주기를 가진 주기적 변동성이 상대적으로 높은 강도를 가지고 있음을 나타낸다. 이러한 주기에서 강한 신호는 특정 환경적 현상이나 자연적 주기가 이 시간 간격을 가지고 있음을 시사할 수 있다. 예를 들어, 달과 태양의 중력이 작용하여 조석 변화를 일으키는 것이 40일 주기의 원인일 수 있다. 또한, 기후 패턴의 변화는 몇 개월 간격으로 대기와 해양 간의 복잡한 상호작용을 일으켜 140일 주기의 변동을 일으킬 수 있다. 계절 변화는 빙하의 녹음이나 강수량 변화를 통해 해수면 상승에 영향을 줄 수 있고, 이는 계절에 따라 주기적인 패턴을 보이게 만든다. 해양 순환 패턴 역시 주기적인 해수면의 변동을 초래할 수 있으며, 인간 활동에 의한 수자원 관리 또한 해수면 상승의 주기성에 영향을 미칠 수 있다.



▶ 강수량 데이터에 대한 주기성 분석

이 강수량 데이터에 대한 주기성 분석 결과를 살펴보면, 20일과 130일 주기 근처

의 주기적 신호가 두드러지게 나타나는 것을 확인할 수 있다. 이러한 뚜렷한 봉우리들은 아마도 자연과 인간의 리듬이 만들어내는 환경의 주기적 변화를 반영하고 있을 것이다. 20일 주기의 봉우리는 짧은 기간에 반복되는 특정 기상 현상이 원인일 수 있다. 예를 들어, 특정 지역에서 발생하는 짧은 순환 기간을 가진 몬순이나, 지역적인 해양 조건 변화에 따른 주기적 강수량 변동 등이 이에 해당한다. 반면에, 130일 주기의 봉우리는 더 긴 주기를 가지는 기후 패턴을 반영할 가능성이 높다. 이는 계절 변화와 관련된 현상일 수 있으며, 장기적인 기후 주기나 엘니뇨와 라니냐 같은 대규모 해양-대기 현상에 의해 발생하는 주기적 변동일 수 있다.

데이터 분석을 깊게 해나가려면, 먼저 데이터의 봉우리들이 실제 기후 현상이나 외부적인 요인들과 연결되어 있는지, 아니면 단지 우연한 변동인지를 알아보기 위해 다른 데이터와 비교해보는 과정이 필요하다. 그리고 데이터에 나타난 주기적인 신호들을 해석할 때는 자연적인 원인뿐만 아니라 인간의 활동 같은 인위적인 요소들도 함께 생각해봐야 한다. 데이터를 수집하고 처리하는 방식에서 생길 수 있는 오류나 특정 패턴, 그리고 데이터를 수집하는 간격 등도 주의 깊게 고려해야 한다. 이런 요소들이 실제로는 일어나지 않는 주기적인 현상을 만들어내거나, 실제 현상을 잘못된 방식으로 보여줄 수 있기 때문이다.

Tip> 파워 스펙트럼 밀도(power spectral density)

Periodogram에서 파워 스펙트럼 밀도를 계산하는 방법은 주어진 시계열 데이터에 대해 수학적으로 주파수별 파워를 구하는 것이다. 이를 쉽게 설명하면,

우리가 가진 시계열 데이터(예를 들어, 일정 시간 동안 측정된 기온)를 가져온다. 이 데이터를 일종의 수학적 공식(푸리에 변환)에 넣어 각기 다른 주파수에서 데이터가 얼마나 강한지를 측정한다. 그 결과를 제공하면, 각 주파수에서 데이터의 '강도'를 나타내는 파워 값을 얻을 수 있다. 마지막으로 이 파워 값을 데이터 포인트의 총개수나 측정 기간으로 나누어서 '밀도'를 계산한다.

간단한 공식으로 표현하면, 파워 스펙트럼 밀도 $P(f)$ 는 푸리에 변환 $F(f)$ 의 절대값의 제곱을 시간 길이 T 로 나눈 것과 같다.

$$P(f) = \frac{|F(f)|^2}{T}$$

여기서 $|F(f)|^2$ 는 푸리에 변환된 값의 제곱(즉, 파워)을 의미하고, T 는 시계열 데이터의 전체 시간을 나타낸다. 이렇게 계산된 $P(f)$ 값이 그래프에 나타나게 된다. 가장 높은 막대가 나타내는 주파수가 가장 큰 파워 스펙트럼 밀도를 가지며, 이는 해당 주파수에서 시계열 데이터가 가장 강한 주기적 변동을 가짐을 의미한다.

데이터 탐색 - 데이터 스무딩을 통한 장기 추세 분석

[Moving Transform] 위젯은 시계열 데이터를 분석하는 데 필수적인 도구다. 이는 데이터를 특정 기간 분석하여 주요 변화와 패턴을 파악할 수 있도록 돕는다. 이 위젯을 활용함으로써, 우리는 데이터의 장기적인 추세를 부드럽게 표현하고, 일시적인 잡음이나 불필요한 변동성을 제거하여, 데이터의 본질적인 흐름과 경향성을 더욱 명확히 파악할 수 있다. [Moving Transform] 위젯을 [Form Timeseries] 위젯과 연결한다.


- ① Sliding Window(슬라이딩 윈도우): 이 기법은 일정한 크기의 '창'을 데이터 시리즈 위에 두고 이를 시간의 흐름에 따라 이동시킨다. 예를 들어, 7일간의 이동 평균을 구할 때, 날마다 새로운 데이터 포인트를 추가하고 가장 오래된 데이터 포인트를 배제하여 계속해서 최신 7일의 데이터에 대한 평균을 갱신한다.
- ② Consecutive Blocks(연속적인 블록): 이 방식은 연속된 데이터의 묶음에 대한 통계치를 계산한다. 한 달 치 데이터를 블록으로 보고, 월별로 평균을 내는 것과 같이, 시간의 블록을 정해 그 안의 데이터를 요약한다.
- ③ Aggregate time periods(특정 시간 구간 집계): 이 방식에서는 사용자가 정한 시간 범위에 따라 데이터를 집계한다. 시간별, 분기별 등의 구간을 설정하여 해당 기간에 대한 평균, 총합, 표준편차 등을 계산한다.

6



▶ 연평균 값 계산하기

우리는 기후 변화의 장기 추세를 관찰할 것이다. 이때, 연 단위로 데이터의 평균값을 살펴보는 것이 중요하다. 이를 위해, 기온, CO₂ 배출량, 해수면 상승량 변수의 평균값을 선택하고, 'Aggregate time periods' 기능을 통해 연평균 값을 계산한다. 계산된 평균값들을 [Moving Transform] 위젯에 [Line Chart] 위젯을 연결하여 시각화하면, 시간에 따른 각 변수의 변화를 비교하고 분석할 수 있다.




▶ 연도별 평균기온, CO₂ 배출량, 해수면 상승량의 변화 시각화

기온 차트는 계절적 변동을 보여주는 것처럼 꾸준한 상승과 하락을 반복하고 있다. 이러한 변동은 계절적인 변화를 나타낼 수 있지만, 차트에 나타난 전체적인 추세를 단정하기에는 변동폭이 일정하지 않다. 상승 추세나 하락 추세를 확인하기 위해서는 각 연도의 평균값들 사이의 경향성을 보다 장기간에 걸쳐 분석해야 하며, 추가적인 데이터와 통계적 방법을 통해 장기 추세를 더 명확히 할 필요가 있다.

CO₂ 배출량 차트는 특정 연도에서의 배출량 증가나 감소를 보여주며, 전반적으로 상승하는 추세를 관찰할 수 있다. 이는 산업 활동과 관련된 인간의 영향을 반영하는 것으로 해석될 수 있으며, 장기적으로 CO₂ 배출량이 증가하는 경향은 기후 변화와 직접적으로 연결될 수 있다.

해수면 상승 차트는 변동성에도 불구하고 상승하는 경향을 보여준다. 이는 지구 온난화에 따른 빙하의 지속적인 녹음과 해수 온도 상승으로 인한 해수면의 팽창을 나타낼 수 있으며, 이러한 해수면 상승은 해안 지역에 중대한 장기적 영향을 미칠 가능성이 있다.

7-1



▶ 기온, CO₂ 배출량, 해수면 상승량의 연평균 변화

이 선형 차트는 [Line Chart] 위젯에서 키보드의 shift키를 이용하여 기온, CO₂ 배

출량, 해수면 상승량의 연간 평균값을 동시에 표시하고 이들 간의 상호 연관성과 시간에 따른 변화 패턴을 한눈에 파악할 수 있게 한다. 각 변수의 구체적인 수치 분석은 포함되어 있지 않지만, 변수들 사이의 관계와 시간에 따른 추세를 간략히 이해하는 데 유용한 개요를 제공할 수 있다.

각 변수의 상관관계를 살펴보면, CO₂ 배출량(빨간색)과 해수면 상승(초록색)이 서로 유사한 추세를 보이는 것처럼 보인다. 두 변수 모두 일정한 상승 추세를 보이며, 특정 시점에서의 변동 패턴도 유사하다. 이는 높은 CO₂ 배출량이 해수면 상승과 관련이 있음을 시사할 수 있다. 평균 온도(파란색)는 일정한 계절적 변동을 보이는데, 이는 자연적인 기후 변화를 나타낼 수 있다. 그러나 이것이 장기적인 CO₂ 배출량 또는 해수면 상승과의 상관관계는 차트만으로는 명확하지 않다. 해수면 상승은 여러 요인에 의해 영향을 받지만, 가장 큰 원인 중 하나는 지구 온난화로 인한 빙하와 얼음의 녹음이다. CO₂ 배출량이 증가함에 따라 온실효과가 강화되어 지구의 평균 온도가 상승하고, 이는 해수면 상승을 가속화할 수 있다.

[소제목]모델 구축 및 훈련

다음은 예측 모델을 구축하고 훈련해 보기 위해 [ARIMA Model] 위젯을 사용한다. [ARIMA Model] 위젯을 [Form Timeseries] 위젯에 연결한다.

ARIMA 모델은 시계열 데이터를 모델링하기 위해 널리 사용되는 방법의 하나이며, ARIMA는 자기회귀 누적이동평균(AutoRegressive Integrated Moving Average)의 약자로, 시계열 데이터의 패턴을 분석하고 미래값을 예측하는 데 사용된다. ARIMA 모델은 ARMA, ARIMA, 또는 ARIMAX 모델을 포함하는데, 각각의 모델은 시계열 데이터의 다양한 특성을 캡처하기 위해 설계되었다.


[ARIMA Model] 위젯을 [Form Timeseries] 위젯에 연결하면 [ARIMA Model]에 오류 표시가 뜨는데, 이는 ARIMA 모델이 시계열 데이터를 모델링하는 과정에서 타겟 변수(target variable)가 있어야 하기 때문이다. ARIMA 모델은 시계열 데이터의 패턴을 분석하고 미래의 값을 예측하기 위한 모델을 만드는데, 이 과정에서 어떤 변수를 예측할 것인지, 즉 타겟 변수가 명확하게 지정되어야 한다. 이를 위하여 우리는 [File] 위젯에서 'Temperature'를 타겟 변수로 설정하기로 한다.



▶ [ARIMA Model] 위젯 설정 화면

ARIMA 모델의 출력은 모델을 통해 생성된 시계열의 미래 예측값(Forecast)과 모델이 실제로 적합된 값(Fitted values), 모델이 각 단계에서 생성한 오차(Residuals)이다. 이 위젯을 클릭하면, 모델의 이름은 모델과 그 매개변수로부터 자동으로 생성되며, 사용자가 원하는 대로 변경할 수 있다. 또한, ARIMA의 매개변수 p , d , q 를 설정할 수 있는데, p (자기회귀 차수)는 모델이 고려할 과거 관측값의 수이고, d (차분 차수)는 데이터를 정상적으로 만들기 위해 필요한 차분 횟수이며, q (이동 평균 차수)는 과거 예측 오차를 현재 예측에 반영하는 데 사용할 값의 수이다. 또한, 설정 창의 'Forecast'에서 'Forecast steps ahead' 옵션은 ARIMA 모델이 미래 몇 단계를 예측할지 설정하는 값이다. 예를 들어, 10으로 설정하면 모델은 다음 10개 시점의 값을 예측한다.

아래 표는 ARIMA 모델을 사용하여 기온 데이터의 예측값을 나타내고 있다. 표에는 세 가지 열이 있는데, ❶ Temperature(forecast)는 모델에 의해 예측된 기온 값을, ❷ Temperature(95%CI low)와 ❸ Temperature(95%CI high)는 예측값의 95% 신뢰구간을 각각 나타낸다.



▶ ARIMA 모델을 사용한 기온 예측값

- Temperature (forecast): 이 열은 ARIMA 모델을 통해 예측된 미래의 기온값을 나타낸다. 예측된 값들은 모델이 학습한 데이터 패턴에 기반하여 계산되었다.
- Temperature (95%CI low): 이 열은 예측된 기온값의 낮은 쪽 95% 신뢰구간 경계를 나타낸다. 즉, 모델이 95% 확신을 두고 예측하는 최저 기온 범위이다.
- Temperature (95%CI high): 이 열은 예측된 기온값의 높은 쪽 95% 신뢰구간 경계를 나타낸다. 즉, 모델이 95% 확신을 두고 예측하는 최고 기온 범위이다.

95% 신뢰구간은 모델이 예측한 기온값이 실제 기온 범위 내에 있을 것으로 예상되는 범위를 제공한다. 신뢰구간이 넓을수록 예측의 불확실성이 높다는 것을 의미하며, 반대로 신뢰구간이 좁을수록 예측의 확실성이 높다는 것을 의미한다. 예를 들어, 모델이 내년의 평균 기온을 15도라고 예측하면서 95% 신뢰구간을 14도에서 16도라고 제시했다면, 모델은 95% 확신으로 실제 기온이 이 범위 내에 있을 것이라고 말한다. 만약 실제 기온이 이 범위 내에 들어온다면, 모델이 신뢰할 수 있는 좋은 예측을 했다고 볼 수 있다. 반대로 신뢰구간이 매우 넓다면, 예를 들어 10도에서 20도라면, 모델이 실제 기온을 예측하는 데 있어 큰 불확실성을 가지고 있다고 볼 수 있다. 이런 경우에는 실제 기온이 신뢰구간 내에 있더라도 모델의 예측이 그다지 정확하지 않을 수 있다.

15


Date	Temperature (fitted)	Temperature (95%CI low)	Temperature (95%CI high)
2020-01-01	1.0	0.5	1.5
2020-01-02	1.5	1.0	2.0
2020-01-03	2.0	1.5	2.5
2020-01-04	2.5	2.0	3.0
2020-01-05	3.0	2.5	3.5
2020-01-06	3.5	3.0	4.0
2020-01-07	4.0	3.5	4.5
2020-01-08	4.5	4.0	5.0
2020-01-09	5.0	4.5	5.5
2020-01-10	5.5	5.0	6.0
2020-01-11	6.0	5.5	6.5
2020-01-12	6.5	6.0	7.0
2020-01-13	7.0	6.5	7.5
2020-01-14	7.5	7.0	8.0
2020-01-15	8.0	7.5	8.5
2020-01-16	8.5	8.0	9.0
2020-01-17	9.0	8.5	9.5
2020-01-18	9.5	9.0	10.0
2020-01-19	10.0	9.5	10.5
2020-01-20	10.5	10.0	11.0
2020-01-21	11.0	10.5	11.5
2020-01-22	11.5	11.0	12.0
2020-01-23	12.0	11.5	12.5
2020-01-24	12.5	12.0	13.0
2020-01-25	13.0	12.5	13.5
2020-01-26	13.5	13.0	14.0
2020-01-27	14.0	13.5	14.5
2020-01-28	14.5	14.0	15.0
2020-01-29	15.0	14.5	15.5
2020-01-30	15.5	15.0	16.0
2020-01-31	16.0	15.5	16.5

▶ ARIMA 모델로 계산한 기온 적합값

위의 표는 ARIMA 모델을 사용해서 기온 시계열 데이터에 대해 계산한 적합값을 보여준다. 적합값이란, 모델이 실제 데이터에 적용되어 나온 결과로, 우리가 데이터에서 볼 수 있는 패턴이나 경향성을 모델이 얼마나 잘 따라가고 있는지를 보여주는 값이다. 'Date' 열은 날짜를 나타내고, 'Temperature (fitted)' 열은 ARIMA 모델을 통해 계산된 그 날짜의 기온 적합값을 나타낸다. 이 적합값은 원래 데이터 포인트에서 모델로 계산된 잔차를 빼서 얻어지는 값이다. 잔차는 실제 관측된 값과 모델

에 의해 예측된 값 사이의 차이로, 모델의 예측이 얼마나 정확했는지를 나타내는 오차의 지표이다. 미래의 기온을 예측하고 싶을 때 이렇게 적합값을 분석하는 것은 모델의 성능을 평가하고, 필요하다면 모델의 매개변수를 조정해서 예측의 정확도를 높일 수 있는 중요한 단계가 될 수 있다. 모델의 적합값이 실제 데이터와 잘 일치한다면, 이 모델이 미렛값을 예측하는 데 신뢰할 수 있음을 의미한다.

16



▶ ARIMA 모델로 계산한 잔차

위의 표는 ARIMA 모델로 예측된 기온 데이터의 잔차를 보여준다. 잔차는 모델이 예측한 값과 실제 관찰된 값 사이의 차이로, 모델의 예측 오차를 나타내는 지표이다. 'Date' 열은 날짜를 나타내며, 'Temperature (residual)' 열은 해당 날짜의 잔차 값을 보여준다. 잔차의 절대값이 크다는 것은 모델이 해당 데이터 포인트를 정확하게 예측하지 못했다는 것을 의미하고, 이는 이상치, 모델 사양 오류, 또는 모델에 포함되지 않은 변수의 영향을 받는 경우일 수 있다. 반면에, 잔차의 절대값이 작다면 모델이 실제 값에 근접한 예측을 했다는 것을 나타낸다.

[소제목]모델 평가

이번에 살펴볼 위젯은 [Model Evaluation]이다. [Model Evaluation] 위젯을 사용하는 이유는 우리가 만든 시간 순서에 따른 예측 모델이 얼마나 잘 작동하는지 확인하기 위해서이다. 다시 말해, 이 위젯은 우리가 과거 데이터로부터 배운 것을 가지고 미래를 예측하는 데 모델이 얼마나 효과적인지를 측정한다.


[Model Evaluation] 위젯에 [Form Timeseries] 위젯을 통해 생성된 시간 순서 데이터와, 평가하고자 하는 [ARIMA Model] 위젯에 연결한다. 이렇게 설정한 후, 모델이 미래 데이터를 얼마나 잘 예측하는지 여러 수치를 통해 알 수 있다. 이 수치

들에는 오차를 나타내는 RMSE, MAE, MAPE 같은 값과, 모델의 성능을 나타내는 POCID, R^2 가 있으며, 모델이 얼마나 정보를 잘 담고 있는지 보여주는 AIC, BIC도 포함된다.

교차 검증이라는 과정을 통해, 시간 순서 데이터를 여러 '폴드'로 나누고 각 폴드에서 모델을 학습시킨 다음, 미래를 예측하게 한다. 이때 각 폴드에서 예측한 결과를 비교함으로써 모델의 일관성과 신뢰도를 평가할 수 있다.

[Model Evaluation] 위젯의 최종 목적은 실제 데이터에 적용했을 때 모델이 얼마나 정확한지를 이해하는 것이다. 이를 통해 모델이 학습 데이터에만 너무 맞춰져 있는지(과적합), 아니면 실제 세계의 데이터에도 잘 맞는지를 알 수 있다. 좋은 모델은 학습 데이터에서의 오차(In-sample errors)와 새로운 데이터에 적용했을 때의 오차(Out-of-sample errors)가 크게 다르지 않아야 한다.

16-1



▶ 모델 평가 결과

ARIMA(2,1,0) 모델을 사용하여 우리는 두 가지 방법으로 예측 성능을 평가했다. 첫 번째는 데이터를 작은 부분으로 나누어 각 부분에서 모델이 실제 값을 얼마나 잘 예측하는지를 확인하는 교차 검증 방법이고, 두 번째는 모델이 학습한 데이터 내에서의 예측 정확성을 측정하는 방법이다.


이 평가를 통해 여러 중요한 지표들이 나타났다. RMSE와 MAE는 예측의 오차를 나타내며, 이 값들이 낮을수록 모델의 예측이 실제 값에 더 가까움을 의미한다. 교차 검증 결과에서 RMSE는 4.012, MAE는 2.183으로 나타났고, 이는 모델이 데이

터를 꽤 잘 예측하고 있음을 보여준다. 하지만 MAPE는 모델의 예측이 평균적으로 실제 값에서 17.5% 벗어나 있음을 나타내며, POCID는 모델이 데이터 변화의 방향을 22.2%의 정확도로 예측함을 보여준다. 마치 날씨 앱이 '오늘 최고 기온이 10도 일 거야'라고 했는데 실제로는 8.25도나 13.1도로 크게 달랐을 때와 비슷하다고 할 수 있다. 또한, R^2 값은 모델이 얼마나 데이터를 잘 설명하고 있는지를 점수로 매긴 건데, 보통 0과 1 사이의 값을 기대한다. 그러므로, 여기서 R^2 가 음수로 나왔다는 건, 모델이 데이터 패턴을 잘 못 잡아내고 있다는 신호이다.

훈련 데이터의 결과도 이와 유사한 양상을 보이는데, RMSE는 5.800, MAE는 3.902로 나타나 교차 검증 결과보다 오차가 크다는 것을 알 수 있다. MAPE 값이 30.9%로 나타나 예측 오차가 더 크다는 것을 확인할 수 있고, POCID는 33.8%로 나타나 훈련 데이터에서 모델이 방향 예측을 조금 더 잘함을 보여준다.

AIC와 BIC 값이 각각 63474, 63496과 63533, 63554로 매우 높게 나타나 모델이 데이터를 설명하기 위해 복잡한 구조를 가짐을 시사한다. 이러한 결과들을 종합해 볼 때, 우리의 모델은 실제 상황에서 새로운 데이터를 마주했을 때 정확하지 않을 수 있음을 알 수 있다. 따라서 모델을 좀 더 단순화하거나, 다른 방식의 모델을 시도하거나, 데이터 처리 방식을 개선해야 할 필요가 있다.

17



▶ 데이터 처리 흐름도

3. 정리하기

우리는 물리팝이 환경 문제에 대한 궁금증을 해결하기 위해, 기후 데이터에 기반한 시계열 데이터를 사용하여 예측적 데이터 분석을 진행하는 과정을 함께 했다.

데이터를 준비하고 전처리하는 과정부터 분석에 필요한 변수를 선택하며, 데이터를 적절히 스케일링하는 기술을 익혔다.

데이터 탐색을 통해 기후 데이터의 주기성과 계절적 변화를 이해하고, 데이터의 장

기적인 패턴과 경향을 파악하는 방법을 배웠다. 이 과정에서 다양한 위젯을 사용하여 데이터의 숨겨진 특성과 변동성을 분석하는 기술을 습득했다.

모델 구축과 훈련 단계에서는 ARIMA 모델을 이용해 기온 데이터의 미래값을 예측하는 경험을 했다. 이 모델을 통해 얻은 예측 결과의 신뢰성을 평가하며, 시계열 데이터의 패턴과 동향을 이해하는 능력을 키웠다.

마지막으로, 모델 평가를 통해 우리가 구축한 모델의 성능을 다양한 지표로 평가하고, 교차 검증을 통해 모델의 일관성과 신뢰도를 검증하는 방법을 배웠다.

이 분석을 통해 우리는 지구 환경이 시간이 지남에 따라 겪고 있는 변화를 좀 더 명확하게 이해할 수 있었다. 온도가 어떻게 변하고 있는지, 비는 얼마나 자주 오는지, 바다의 물은 얼마나 높아지고 있는지, 그리고 공기 중에는 얼마나 많은 이산화탄소(CO₂)가 있는지 등을 살펴봤다. 이러한 정보는 우리의 일상생활과 환경이 어떻게 연결되어 있는지를 보여주는 중요한 통찰을 제공하며, 미래 환경 변화에 대한 예측을 가능하게 한다. 더불어, 더 나은 환경 정책을 만들거나, 어떻게 하면 지구 온난화를 늦출 수 있을지 계획을 세우는 것과 같이 우리가 앞으로 어떻게 환경을 보호하고 지구를 더 좋은 곳으로 만들 수 있을지를 결정하는 데 도움을 줄 것이다.